

Deteccion de Equipo Pesado y Maquinaria en Sitios de Construcccion

Mini-Informe Ejecutivo | Vision Artificial - Maestria IA para AECO

1. Resumen Ejecutivo

Este proyecto implementa un sistema de deteccion automatica de equipo de proteccion personal (EPP), maquinaria pesada y vehiculos en sitios de construccion utilizando YOLOv8n. Se entreno con un subconjunto de ~200 imagenes (seed=42) del dataset Construction Site Safety de Roboflow Universe (CC BY 4.0). El modelo alcanza **mAP@0.5 = 0.5245** y **Precision = 0.6817**, cumpliendo los criterios de exito definidos para el proyecto.

2. Problema

Los accidentes en obras de construccion representan una de las principales causas de lesiones laborales graves y muertes en el sector. La verificacion manual del uso de EPP y la supervision de zonas de riesgo con maquinaria pesada son procesos costosos, inconsistentes y propensos a errores humanos. Se requiere un sistema de vision artificial que automatice la deteccion en tiempo real.

3. Metodologia

Dataset: Construction Site Safety (Roboflow Universe, CC BY 4.0) con 10 clases: Hardhat, Mask, NO-Hardhat, NO-Mask, NO-Safety Vest, Person, Safety Cone, Safety Vest, machinery, vehicle.

Subconjunto: ~200 imagenes train / ~50 valid, seleccion aleatoria con seed=42.

Modelo: YOLOv8n (Nano, ~3.2M parametros) preentrenado en COCO, fine-tuned por 30 epocas con batch=16, imgsz=640 en Google Colab con GPU T4. Ultralytics 8.4.21, PyTorch 2.10.0+cu128.

Evaluacion adicional: Inferencia baseline (COCO sin fine-tune) + exploracion con MobileSAM para segmentacion zero-shot usando bounding boxes de YOLO como prompts.

4. Resultados

Metrica	Valor	Objetivo	Cumple
Precision (P)	0.6817	>= 0.50	Si
Recall (R)	0.4440	>= 0.40	Si
mAP@0.5	0.5245	>= 0.40	Si
mAP@0.5:0.95	0.2294	—	—

Metricas por clase (Top 3 y Bottom 3):

Clase	P	R	mAP@50	mAP@50-95
Mask (mejor)	0.896	0.857	0.916	0.234
Safety Vest	0.790	0.500	0.686	0.385
machinery	0.694	0.618	0.639	0.329
NO-Mask	0.608	0.296	0.329	0.120
Safety Cone	0.545	0.346	0.410	0.138
vehicle (peor)	0.521	0.146	0.215	0.107

Hallazgo clave: Mask logra el mejor rendimiento (mAP50=0.92) por su apariencia visual distintiva. Vehicle es la clase mas dificil (Recall=0.15), indicando que el subconjunto reducido no contiene suficiente variedad de vehiculos para generalizar.

5. Analisis de Errores

Falsos Positivos: Objetos naranjas confundidos con conos (correlacion color-clase), ropa brillante clasificada como chaleco, y detecciones duplicadas en maquinaria/vehiculos por ambigüedad semantica.

Falsos Negativos: Personas ocultas por maquinaria no detectadas (escenario critico), maquinaria lejana o parcialmente fuera de cuadro omitida, y violaciones de EPP no detectadas en grupos densos de trabajadores.

La Precision (0.68) supera al Recall (0.44): el modelo es conservador. En seguridad, los FN son mas peligrosos que los FP. Se recomienda bajar el umbral de confianza para priorizar Recall en clases criticas.

6. Limitaciones

- Subconjunto reducido (~200 imgs) limita la generalizacion, especialmente en vehicle y Safety Cone.
- Solo 10 clases; no detecta arnes, lentes protectores, guantes ni proteccion auditiva.
- Entrenado solo con imagenes diurnas; rendimiento no garantizado en turnos nocturnos.
- Las imagenes del dataset no representan necesariamente condiciones de obra en Mexico.
- No apto para toma de decisiones automatizadas sin supervision humana.

7. Gobernanza y Etica

Privacidad: Imagenes contienen rostros identificables. Despliegue real requiere consentimiento informado, difuminado de rostros y politica de retencion de datos (max. 30 dias).

Sesgo: Posible sesgo geografico (imagenes no mexicanas), temporal (solo diurnas) y demografico (deteccion de mascarilla puede variar por tono de piel).

Transparencia: Los trabajadores deben saber que estan siendo monitoreados. Los supervisores deben conocer las limitaciones del modelo antes de actuar sobre las alertas.

8. Licencias

Componente	Licencia
Codigo del proyecto	MIT
Dataset	CC BY 4.0
YOLOv8 (Ultralytics)	AGPL-3.0
MobileSAM	Apache 2.0