

# Detección de Equipo Pesado y Maquinaria en Sitios de Construcción

MODULO 4 TEMA 3 | VISION COMPUTACIONAL

# El Problema

**65%**

de accidentes fatales en  
construcción son prevenibles  
con EPP

**~2,800**

imágenes del dataset  
Construction Site Safety  
(Roboflow Universe)

**10**

clases de detección:  
EPP, maquinaria,  
vehículos, señalización

La supervisión manual del uso de EPP es costosa, inconsistente y propensa a errores. Un sistema de visión artificial automatiza la detección en tiempo real para complementar la supervisión humana y reducir accidentes.

# Metodología

1

## Dataset

Construction Site Safety  
Roboflow Universe  
CC BY 4.0

2

## Subconjunto

~200 train / ~50 valid  
Seed=42  
Selección aleatoria

3

## Entrenamiento

YOLOv8n (Nano)  
30 épocas, batch=16  
imgsz=640, GPU T4

4

## Evaluación

Métricas P/R/mAP  
Inferencia visual  
SAM zero-shot

# Resultados

Precision

0.6817

Recall

0.4440

mAP@0.5

0.5245

mAP@50-95

0.2294

Criterios de éxito:


mAP@0.5  $\geq$  0.40: 0.5245 → CUMPLE ✓

Precision  $\geq$  0.50: 0.6817 → CUMPLE ✓

Recall  $\geq$  0.40: 0.4440 → CUMPLE ✓

Mejor: Mask (mAP50=0.92) | Peor: vehicle (mAP50=0.22)

# Métricas por Clase



mAP@0.5 por clase (ordenado de mayor a menor)

# Análisis de Errores

## FALSOS POSITIVOS

FP-1: Objetos naranjas confundidos con conos de seguridad

FP-2: Ropa brillante clasificada como chaleco de seguridad

FP-3: Detecciones duplicadas en maquinaria/vehículos

## FALSOS NEGATIVOS

FN-1: Personas ocultas por maquinaria no detectadas (CRÍTICO)

FN-2: Maquinaria lejana o fuera de cuadro omitida

FN-3: Violaciones EPP en grupos densos no detectadas

**Precision (0.68) > Recall (0.44): el modelo es conservador. En seguridad, los FN son más peligrosos. Se recomienda bajar el umbral de confianza para priorizar Recall en clases críticas.**

# Gobernanza y Ética de IA

## Privacidad

Consentimiento informado  
Difuminado de rostros  
Política de retención

## Transparencia

Trabajadores informados  
Limitaciones documentadas  
Confianza del sistema

## Sesgo

Geográfico, temporal,  
demográfico. Validar con  
datos locales (México)

## Riesgos

$FN > FP$  en seguridad  
Priorizar Recall en  
clases críticas

## Licencias

Código: MIT  
Dataset: CC BY 4.0  
YOLO: AGPL-3.0

## Limitaciones

No sustituye supervisores  
Solo 10 clases de EPP  
Solo condiciones diurnas

**0.52**

mAP@50

## Conclusiones y Trabajo Futuro

- Todos los criterios de éxito cumplidos ( $P=0.68$ ,  $R=0.44$ ,  $mAP50=0.52$ )
- Mask es la clase con mejor rendimiento ( $mAP50=0.92$ ); vehicle la peor (0.22)
- Las clases de violación (NO-\*) necesitan más datos para mejorar Recall
- SAM complementa YOLO con segmentación zero-shot sin entrenamiento extra
- Despliegue real requiere gobernanza robusta y supervisión humana

Trabajo futuro: más datos, clases adicionales de EPP, despliegue edge con TensorRT